

LISTA DE EXERCÍCIOS — POWER BI E ORANGE DATA MINING

Neste exercício você será capaz de:

criar dados → armazenar dados → integrar dados → visualizar → avaliar qualidade → tratar dados → minerar dados.

Orientações gerais

Nesta lista, você irá criar pequenas bases de dados, analisá-las no Power BI e no Orange Data Mining e, posteriormente, investigar problemas de qualidade dos dados.

As bases deverão ser criadas pelos próprios alunos. Você poderá utilizar o Excel ou outra ferramenta para auxiliar na geração dos registros, que **DEVERÃO SER FICTÍCIOS**. Mesmo assim, você será responsável por conferir os dados gerados.

Organização das atividades

Exercícios 1, 2 e 3: criação e exploração de bases corretas e completas, sem dados vazios ou outros problemas de qualidade.

Exercício 4: criação de uma versão problemática de uma base já existente, introduzindo dados vazios e valores inválidos.

Exercício 5: criação de uma base com problemas de acurácia, duplicidade e consistência.

Exercício 6: investigação de problemas de qualidade em dados armazenados no MariaDB.

Muito importante: sempre que uma atividade pedir uma base problemática, mantenha a versão original correta salva separadamente. Assim, será possível comparar a base correta, a base com problemas e a base após o tratamento.

Conceitos trabalhados

Nesta lista serão trabalhados:

Dados vazios: informações que deveriam estar preenchidas, mas não estão.

Validade: verifica se o valor respeita as regras definidas para aquele campo.

Acurácia: verifica se o valor corresponde à realidade ou a uma fonte confiável.

Duplicidade: identifica registros que aparecem mais de uma vez indevidamente.

Consistência: verifica se diferentes informações são compatíveis entre si.

OBS: Nesta etapa, não serão trabalhados NaN, outliers ou ruídos.

PARTE 1 — POWER BI

EXERCÍCIO 1 — VENDAS

Ferramentas: Excel e Power BI

Crie uma base de vendas com aproximadamente 30 registros.

Utilize as seguintes colunas:

ID da venda;

data;

produto;

categoria;

quantidade;

valor unitário;

estado do cliente.

A base deverá estar correta e completa, sem células vazias ou valores inválidos.

Depois:

Importe a base para o Power BI.

Crie um cartão mostrando o valor total das vendas.

Crie um gráfico mostrando as vendas por produto.

Crie um gráfico mostrando as vendas por estado.

Crie um gráfico mostrando a evolução das vendas ao longo do tempo.

Responda:

- a) Qual produto vendeu mais?
- b) Qual estado apresentou mais vendas?
- c) Qual foi o valor total vendido?

EXERCÍCIO 2 — GESTÃO ACADÊMICA

Ferramentas: Excel e Power BI

Crie quatro pequenas tabelas:

Alunos: aproximadamente 30 alunos.

Cursos: aproximadamente 4 cursos.

Disciplinas: aproximadamente 12 disciplinas.

Matrículas: aproximadamente 100 registros.

As tabelas deverão possuir identificadores, como:

ID do aluno;

ID do curso;

ID da disciplina;

ID da matrícula.

Primeiro, crie tudo corretamente no Excel.

Depois:

Importe o arquivo para o Power BI.

Crie os relacionamentos entre as tabelas.

Mostre a quantidade de alunos por curso.

Mostre a quantidade de matrículas por disciplina.

Responda:

a) Qual curso possui mais alunos?

b) Qual disciplina possui mais matrículas?

c) Por que utilizar várias tabelas relacionadas pode ser melhor do que colocar todas as informações em uma única tabela?

PARTE 2 — ORANGE DATA MINING

EXERCÍCIO 3 — CONHECENDO OS DADOS

Ferramentas: Excel, CSV e Orange

Crie uma base com aproximadamente 100 clientes.

Utilize:

ID do cliente;

idade;

cidade;

estado;

renda;

quantidade de compras;

valor total das compras.

A base deve estar correta e completa.

Depois:

Salve a base como CSV.

Abra a base no Orange.

Observe os atributos e seus tipos.

Utilize as ferramentas de visualização do Orange para explorar os dados.

Responda:

- a) Qual faixa etária possui mais clientes?
- b) Qual estado possui mais clientes?
- c) Qual é a distribuição da renda?
- d) Existe alguma relação entre quantidade de compras e valor total das compras?

EXERCÍCIO 4 — DADOS VAZIOS E VALIDADE

Ferramentas: Excel, CSV e Orange

Utilize a base do Exercício 3.

Primeiro, faça uma cópia da base.

A base original deverá permanecer correta.

Na cópia, insira alguns problemas.

Dados vazios

Insira aproximadamente:

5 idades vazias;

5 rendas vazias;

5 estados vazios;

5 quantidades de compras vazias.

Dados inválidos

Insira alguns valores como:

idade = 250;

idade = -5;

estado = XX;

renda = -3000;

quantidade de compras = -10.

Depois:

Salve a base problemática como CSV.

Abra no Orange.

Procure os dados vazios.

Procure os valores inválidos.

Registre os problemas encontrados.

Faça o tratamento da base.

Responda:

a) Quantos dados vazios foram encontrados?

b) Quais valores eram inválidos?

c) Qual é a diferença entre um dado vazio e um dado inválido?

EXERCÍCIO 5 — ACURÁCIA, DUPLICIDADE E CONSISTÊNCIA

Ferramentas: Excel, CSV e Orange

Crie uma nova base com aproximadamente 100 clientes.

Agora você deverá criar três tipos de problemas.

1. Acurácia

Crie uma pequena tabela chamada Fonte de Referência.

Ela deverá conter informações consideradas corretas.

Altere alguns valores da base principal para que não correspondam à fonte de referência.

Exemplo:

Cliente 10 → Estado na base: SP

Fonte de referência → Estado correto: RJ

2. Duplicidade

Copie aproximadamente 5 registros e insira-os novamente na base.

Depois tente identificar as duplicidades.

3. Consistência

Crie alguns registros com informações incompatíveis.

Exemplo:

Idade: 20 anos

Data de nascimento: 1980

Depois importe a base para o Orange e investigue os problemas.

Responda:

- a) Um valor pode ser válido e ainda assim estar errado? Dê um exemplo.
- b) O que é uma duplicidade?
- c) O que significa dizer que dois dados são inconsistentes?
- d) Explique, com suas palavras, a diferença entre validade e acurácia.

EXERCÍCIO 6 — ORANGE + MARIADB

Ferramentas: MySQL/MariaDB e Orange

Crie um pequeno banco de dados contendo:

aproximadamente 30 clientes;

aproximadamente 10 produtos;

aproximadamente 100 vendas.

Primeiro, crie as informações corretamente.

Depois, introduza alguns problemas já estudados:

dados vazios;

valores inválidos;

duplicidades;

inconsistências.

Conecte o Orange ao banco de dados e investigue as informações.

Responda:

- a) Quais problemas foram encontrados?
- b) Em quais campos eles apareceram?

c) Quantos registros foram afetados?

d) O fato de os dados estarem armazenados em um banco de dados garante que eles estejam corretos? Explique.